

Painel Econômico BR

Pipeline de dados da economia brasileira com Apache Airflow 3, Postgres, Metabase e CI/CD num homelab Proxmox

4 DAGs em produção	3 fontes públicas	12 checagens de qualidade	115 testes automatizados
26 anos de Selic e câmbio	~600 municípios com preço semanal	11 mi coletas de preço processadas	3 dashboards como código

Marco · github.com/marcoADevOps/painel-economico-br

Documentação gerada em 30/09/2026

1. Visão geral

O projeto coleta todo dia indicadores públicos do **Banco Central** (Selic e dólar PTAX), do **IBGE** (IPCA por região e taxa de desocupação) e da **ANP** (preço dos combustíveis por município). Os dados passam por três camadas num Postgres (*raw*, *staging* e *marts*) e são publicados em dashboards no Metabase.

O ambiente roda 24/7 numa VM do homelab, sem IP público, e é tratado como produção: deploy automático a cada push, alertas no Telegram, monitoramento externo, backup verificado e testes de desligamento.

Objetivos de engenharia

- **Idempotência:** reexecutar qualquer DAG, ou recarregar o histórico inteiro, não duplica dados (upsert por chave natural, testado em produção).
- **Resposta bruta primeiro:** tudo o que vem das fontes é guardado sem alteração antes de ser transformado, para permitir auditoria e reprocessamento.
- **Dado ruim não chega ao usuário:** um portão de qualidade roda antes de publicar a staging.
- **Janela pela data lógica:** o período processado vem da data lógica do Airflow, nunca de *now()*. Com isso, o *catchup* e o *backfill* funcionam sem código extra.
- **Nada sensível no Git:** o repositório é público; segredos existem só no *.env* da VM e são gravados por scripts que não os mostram na tela.

Stack

Camada	Tecnologia
Orquestração	Apache Airflow 3.3 (LocalExecutor, TaskFlow API, Assets, mapeamento dinâmico)
Armazenamento	PostgreSQL 16 (metadados, warehouse e configuração do Metabase)
Visualização	Metabase v0.63, só leitura na camada marts
Infraestrutura	Docker Compose numa VM Ubuntu 24.04 (2 vCPU, 4 GB) no Proxmox
CI/CD	GitHub Actions, runner self-hosted, imagens no GHCR
Observabilidade	Telegram, Uptime Kuma (LXC separado), healthchecks
Qualidade de código	ruff, pytest (115 testes), teste de importação dos DAGs

2. Arquitetura

Painel Econômico BR: arquitetura

Airflow 3 · Postgres 16 · Metabase · Docker Compose numa VM Proxmox · CI/CD com GitHub Actions (runner self-hosted)




Figura 1: componentes, fluxo de dados e operação.

As três DAGs de origem seguem o mesmo fluxo: extração para *raw*, transformação para *staging*, checagens de qualidade e publicação de um **Asset**. O DAG *marts* é disparado quando **qualquer** fonte publica (condição OU), de modo que uma fonte com falha não segura as outras. Cada *mart* é reconstruído numa única transação.

O Uptime Kuma e a cópia dos backups ficam **fora da VM**: se a VM cair, o monitoramento continua avisando e as cópias continuam disponíveis.

3. Fontes e DAGs

DAG	Fonte e dados	Agenda	Histórico
bcb_sgs	API SGS: Selic meta (série 432) e PTAX venda (série 1)	dias úteis 19h	desde 2000
ibge_sidra	API SIDRA: IPCA (tabelas 1419 e 7060) por região; desocupação (tabela 4099) por região e UF	dias úteis 10h	desde 2012
anp_precos	CSVs da ANP: preço por posto, produto e data; agregado por semana, município e produto	segundas 11h	desde 2016
marts	4 tabelas analíticas a partir da staging	por Asset	—

Cada execução agendada reprocessa uma janela para trás (10 dias no BCB, ~13 meses no IBGE, 4 meses na ANP). Isso cobre dados publicados com atraso ou revisados, e preenche o período em que a VM ficou desligada. Cargas históricas são disparadas manualmente com os parâmetros *start* e *end*.

Capacidade e desempenho medidos

Item	Medida
Carga histórica da ANP (2016–2026)	47 arquivos, ~1,5 GB baixados, ~11 minutos
Pico de memória de uma task da ANP	~450 MB (no máximo 2 arquivos em paralelo)
Staging / marts de combustíveis	1,17 mi / 1,26 mi linhas; ~11 mi de coletas
Banco de dados / arquivos originais	446 MB / 278 MB (.csv.gz)
Backup diário (dump)	~1,6 MB; os arquivos originais são copiados de forma incremental
Metabase	~1,05 GB (heap 640 MB); limite do contêiner 1,25 GB

4. Camadas de dados e qualidade

Camada	Conteúdo	Garantia
raw	resposta original de cada requisição (JSON) ou arquivo (.csv.gz em disco, com SHA-256)	auditoria e reprocessamento
staging	dados tipados e limpos, com chave natural	upsert idempotente
marts	monthly_indicators, ipca_by_region, unemployment_by_region, fuel_prices_weekly	reconstrução numa transação

Portão de qualidade

Cada fonte roda 4 checagens depois de carregar a staging e **antes** de publicar o Asset. Uma violação falha a task na hora, sem novas tentativas (repetir não conserta dado ruim), envia um alerta com exemplos das linhas problemáticas e mantém os marts na última versão boa.

Checagem	Regra (exemplos)
Duplicados	nenhuma chave natural repetida
Nulos	colunas obrigatórias preenchidas
Faixa plausível	Selic entre 0 e 50%; PTAX entre R\$ 0,50 e R\$ 20; IPCA mensal entre -5% e 10%; média semanal da gasolina entre R\$ 0,50 e R\$ 20; GLP entre R\$ 20 e R\$ 300
Atraso	medido em relação à data da execução: 7 dias (BCB), 80 e 240 dias (IBGE), 100 dias (ANP)

5. Dashboards

Os dashboards são definidos como código (*ops/metabase/provision.py*) e provisionados pela API do Metabase: 3 dashboards e 18 perguntas SQL sobre os marts. O script é idempotente e executa cada pergunta para detectar erros de SQL.

Indicadores macroeconômicos ⓘ



Indicadores macroeconômicos

Selic meta (Copom), IPCA Brasil (IBGE) e dólar PTAX (Banco Central), mês a mês. O juro real é ex-post: $(1 + \text{Selic}) / (1 + \text{IPCA 12 meses}) - 1$. O IPCA das tabelas usadas começa em 2012.

Selic meta (% a.a.)

...

13.75

IPCA 12 meses (%)

...

4.22

Juro real (%)

...

9.38

Dólar PTAX (R\$)

...

5.22


Selic meta × IPCA 12 meses

● Selic meta (% a.a.) ● IPCA 12 meses (%)



Juro real ex-post ao longo do tempo (%)

...



Dólar PTAX, média mensal (R\$)

...



Figura 2: indicadores macroeconômicos.

Inflação e desemprego por região

IPCA (índice geral) por região metropolitana e capital pesquisadas pelo IBGE, e taxa de desocupação da PNAD Contínua (trimestral).




Figura 3: inflação e desemprego por região.

Preços de combustíveis (ANP)

Média semanal (domingo a sábado) dos preços de revenda coletados pela ANP, ponderada pelo número de coletas. Lacunas da fonte: ago-out/2020, 1º semestre de 2022 (não publicado) e uma semana de set/2022.



Gasolina: 10 municípios mais caros (última semana)

Município	UF	Preço médio (R\$/l)	Coletas
PARINTINS	AM	8.99	5
DELMIRO GOUVEIA	AL	7.61	10
BOA VISTA	RR	7.57	15
ARARIPINA	PE	7.56	10
ITAPIPOCA	CE	7.49	8
PORTO VELHO	RO	7.46	10
VILHENA	RO	7.39	7
PIMENTA BUENO	RO	7.39	8
PETROLINA	PE	7.35	5
CODO	MA	7.31	7

10 linhas

Gasolina: 10 municípios mais baratos (última semana)

Município	UF	Preço médio (R\$/l)	Coletas
FORMOSA	GO	5.74	6
ARACATUBA	SP	5.77	2
PONTA GROSSA	PR	5.89	1
ESTEIO	RS	5.9	8
CANOAS	RS	5.92	12
TAUBATE	SP	5.92	6
SETE LAGOAS	MG	5.92	7
NOVO HAMBURGO	RS	5.92	12
SAPUCAIA DO SUL	RS	5.93	8
PASSOS	MG	5.95	8

10 linhas




Figura 4: preços de combustíveis (ANP).

6. CI/CD e operação

Entrega contínua

- Em cada push na *main*: **ruff** e **pytest** numa imagem de teste, build da imagem de produção, publicação no GHCR com a tag do commit e *docker compose up --wait* na VM.
- O runner self-hosted só roda em push na main. PRs de fork rodam nos runners do GitHub, porque o repositório é público.
- **Rollback**: trocar *AIRFLOW_IMAGE* no .env da VM por uma tag anterior.

Confiabilidade

- **Alertas**: task com falha → Telegram, com o link do log, em ~15 minutos (tentativas após 2, 4 e 8 min); erros de parâmetro avisam na hora.
- **Uptime Kuma**: ping da VM, saúde do scheduler e push do backup. Testado: scheduler parado → DOWN em 19 s.
- **Backup**: pg_dump diário verificado, com cópia puxada pelo host do Proxmox via rsync somente leitura; a restauração foi testada.
- **Desligamento**: VM desligada e religada → todos os serviços voltam sozinhos, com dados idênticos e alertas de DOWN e UP.

7. Lições aprendidas

Cada fonte pública tinha uma armadilha que só apareceu no teste real, não na documentação.

Problema	Onde	Solução
HTTP 200 com página HTML de erro	BCB	validar o conteúdo; nova tentativa por janela
Carga longa recomeçava do zero a cada falha	BCB	pular janelas já guardadas: de 40 min de falhas para 1 min
ID de localidade repetido entre níveis	IBGE	nível territorial na chave natural
Accept: application/json → HTTP 401	ANP (gov.br)	pedir text/html e */*
Mesmos dados em arquivos mensais e semestrais	ANP	o semestral substitui os mensais (evita dupla contagem)
Nomes irregulares, arquivo sem extensão, .zip	ANP	descobrir os links e classificar pelo nome
Downloads de 85 MB cortados	ANP	retomar com HTTP Range e conferir o tamanho
Provider usa psycpg 3	Airflow	SQL só com a DB-API padrão
dags test disputando a task com o scheduler	Airflow	testar DAGs ativos só com execuções normais
OutOfMemoryError: Metaspace	Metabase	limitar o heap, não o metaspace; swap

Próximos passos

- Dashboards cruzando fontes (combustível × IPCA, câmbio × gasolina, preço × desocupação por UF).
- IPCA nacional desde 1979 (tabela SIDRA 1737), para completar o juro real desde 2000.
- Expor o dashboard com Cloudflare Tunnel e autenticação.